SafeTrace KZ: как работает программа и что изменилось

ОТЧЁТ О ПРОДУКТЕ И НОВОЙ ПРОВЕРКЕ · 22 ОКТЯБРЯ 2026

Отчёт об итерации v4, 22 октября 2026 года, Asia/Qyzylorda. Документ предназначен для человека, который впервые знакомится с проектом. Техническая конфигурация этой итерации: приложение 2.2.1, rules-4.0, pipeline-2.2.1. Решение о рекомендуемой версии и измеренные результаты приведены ниже.

1. Что это за программа

SafeTrace KZ помогает аналитику проверять признаки скрытого продвижения онлайн-казино. Пользователь передаёт текст, ссылку или изображение. Программа читает доступный текст, распознаёт надписи и QR, проверяет разрешённые переходы, показывает основания связей и формирует досье.

Рабочая единица - случай. В нём можно объединить до 20 материалов, сохранить наблюдения и записать решение проверяющего. Результат включает индекс приоритета от 0 до 100, полноту данных, объяснение, маршрут и граф. Индекс помогает выбрать порядок ручной проверки; он не является вероятностью нарушения или решением о виновности.

Проект относится к треку 2 «Скрытая игра». Типичный пример: в публикации есть обещание бонуса и приглашение, но нет слова «казино». Адрес ведёт через посредника к странице с игровыми признаками. Другая публикация приходит к тому же назначению и содержит тот же идентификатор. Аналитик может открыть каждый шаг и проверить источник связи.

2. Какую работу он упрощает

При обычной проверке нужно прочитать изображение, переписать адрес без ошибки, пройти цепочку ссылок, отличить рекламу от предупреждения, сопоставить материалы и сохранить подтверждения. Ошибка в одном символе URL может привести к совершенно другому назначению. А совпадение слов «бонус» и «казино» ещё не означает продвижение: это может быть новость или урок о рисках.

SafeTrace собирает эти действия в одном локальном процессе. Практическая ценность - доступ к исходнику каждого вывода и сохранение истории, а не только выдача числа. Экономия времени человека пока не измерена: автоматические проверки работоспособности не заменяют наблюдение за независимым аналитиком.

3. Полный путь материала

1. Пользователь создаёт случай из текста, URL, PNG/JPEG/WebP или JSONL. Сервер проверяет формат и лимиты, сохраняет оригиналы.
2. PaddleOCR читает пиксели изображения. Сохраняются исходные строки, координаты и уверенность. OpenCV отдельно распознаёт QR.

3. Локальные правила выделяют призывы, игровые признаки, бонусы и альтернативный контекст на русском, казахском и в части транслита. Каждая цитата связана с исходным фрагментом.

4. Адреса проходят проверку. В демонстрации используются собственные синтетические страницы; в реальном режиме - явный список разрешённых доменов и ограничения сети.

5. Система различает HTTP-редирект и ссылку внутри документа, сохраняет извлечённый текст и SHA-256 ответа, время, причину остановки и наблюдения назначения. Полное тело HTTP-ответа не хранится в досье. Ошибка одной ветви оставляет результаты остальных.

6. Призыв сопоставляется с доступным назначением именно своей ветви. Индекс рассчитывается для материалов отдельно; дубли не усиливают его как независимые публикации.

7. Аналитик открывает основания, при необходимости уточняет спорный OCR-адрес, оставляет решение и скачивает ZIP.

ZIP содержит читаемый HTML, полный JSON, оригиналы и manifest с SHA-256. Контрольная сумма подтверждает соответствие файла манифесту; она не подтверждает истинность содержания, автора или юридический статус.

4. Что улучшено во внутреннем механизме

В предыдущей версии перенос строки мог разрывать связь призыва с контекстом. Информационное приглашение к памятке иногда получало признаки другого игрового назначения. Несколько адресов и повтор одного материала также требовали более точного учёта.

Новая версия учитывает область призыва и конкретную ветвь маршрута. Одиночный перенос внутри предложения не уничтожает контекст, а абзацы остаются границами. Предупреждение в одном фрагменте не отменяет отдельное рекламное предложение; одновременно приглашение на урок не получает чужую игровую ссылку. Если цель неоднозначна, это явно показано как неполнота.

Повтор одинакового содержания, даже с другим заявленным названием источника, сохраняется, но не становится независимым подтверждением. Для повторного идентификатора учитывается точная область назначения. Ни общий код, ни общий домен инфраструктуры не устанавливают владельца.

Сомнительные OCR-адреса больше не открываются молча. Программа показывает первичный результат, причины сомнения и ограниченные предложения дополнительной английской модели. Человек сверяет их с оригиналом. Уточнение сохраняет старое значение и историю, а повторный результат помечается как полученный с участием аналитика. Это участие не включается в автоматические метрики.

При проверке интерфейса найден и исправлен ещё один дефект: повтор после отмены мог терять запись незавершённого анализа. Теперь история сохраняет такой анализ вместе с OCR и этапами даже без рассчитанного индекса. Оригиналы и решения остаются доступны после перезапуска.

5. Что показали измерения

На одинаковых 80 новых авторских случаях старая v3 получила TP31 / FP9 / TN31 / FN9, новая v4 - TP30 / FP2 / TN38 / FN10. Доля верных срабатываний (precision) выросла с 77,5% до 93,75%, общий recall снизился с 77,5% до 75%, ложные тревоги среди отрицательных (FPR) - с 22,5% до 5%. Достаточно данных в 74/80 вместо 75/80. Шесть положительных отказов остаются в десяти пропусках.

Девять классификаций исправлены, три испорчены. V4 проходит правило выпуска, записанное до теста, но цели проекта precision 95% и recall 80% не достигнуты. Wilson 95%: precision 79,85-98,27%, recall 59,81-85,81%, FPR 1,38-16,50%. Независимой разметки нет; интервалы не устраняют авторское смещение.

На изображениях recall снизился с 12/16 до 10/16, ложных тревог стало 0/16 вместо 2/16. Первичный OCR дал одинаковые 22 точных URL из 31 и девять неверных в обеих версиях. V4 автоматически приняла 21 правильный и ноль неверных адресов; остальные десять не приняты. Правильный набор среди подсказок доступен в 27/28 изображений с видимым URL. QR прочитаны в 8/8 у обеих версий. Это выигрыш в надёжности принятия адресов с потерей автоматической полноты, а не доказательство улучшения всех показателей OCR.

Оставшиеся ошибки: казахские и составные русские отрицания, межфразовая связь призыва, смешение алфавитов в слове «Регистрируйся», остановка правильного международного пути и четыре недоступных назначения. Для двух остановленных адресов отметка достаточности слишком оптимистична. Эти случаи сохранены в разборе, правила после теста не менялись.

На отдельном разработческом OCR-наборе из 40 новых изображений первичное точное чтение адреса получено в 37 случаях. Автоматически приняты 35 правильных адресов и ни одного неверного; пять остановок включали два корректных международных пути. Правильный вариант среди исходного чтения и подсказок был доступен в 39 случаях. Это диагностический набор разработки, а не независимое подтверждение качества.

Из девяти известных ошибок v3 две классификации исправлены на регрессии: пропуск из-за переноса и ложная тревога на информационном материале. Два неверных кириллических URL остановлены и получили правильное предложение для сверки. Некоторые ASCII-ошибки, например потеря буквы в пути, остаются. Четыре намеренно недоступных назначения не заменялись выдуманными страницами.

6. Скорость и условия работы

На 32 изображениях нового итогового теста v4: медиана всего процесса 4,45 с, p95 18,80 с; внутри OCR - 4,35 с и 18,69 с. Основная модель уже загружена, кэш выключен. Предварительная загрузка основной модели заняла 5,09 с. Сложные повороты объясняют длинный хвост; внешний интернет и облако здесь не измеряются.

В отдельном свежем API-процессе первый новый снимок обработан за 9,96 с с загрузкой модели, повтор с кэшем - за 0,196 с. Шесть разных снимков, поданных без ожидания результата, завершились; активная обработка заняла 3,23-3,89 с на случай, ожидание после создания - до 14,47 с. Это небольшой технический опыт на одном CPU, не оценка промышленной мощности или скорости человека.

Программа работает на Windows CPU после установки зависимостей и моделей. GPU, Docker, платная база и облачный ключ для основного процесса не нужны. При первом запуске OCR загружает модели; затем повтор тех же пикселей может использовать кэш. Эти режимы измеряются отдельно. Один исполнитель обрабатывает ограниченную очередь; отмена выполняется между этапами и не обязана мгновенно прервать уже начатый OCR.

Отсутствие сети не мешает локальным OCR, правилам, синтетическим маршрутам, истории и экспорту. Оно не даёт доступа к новым внешним страницам. Gemini подготовлен как отдельный адаптер, но живой API без разрешённого ключа не проверен.

7. Проверки и сохранность

До итогового теста выполнены 315 backend-тестов, 21 frontend-тест, проверки типов, lint и production-сборка. Отдельно проверен настоящий HTTP/TLS-клиент на контролируемом стенде: сертификаты, SNI, относительные переходы, изменение ответа, кодировки, лимиты и блокировка опасных адресов. Это технические испытания, не полевой пилот на сайтах.

Настоящим браузером пройден новый PNG: распознавание → спорный перенесённый URL → оригинал и координаты → явное уточнение → маршрут → второй материал → решение → перезагрузка → скачивание ZIP. Проверены узкий экран, источник стрелки графа, неверная схема URL, отключённый сервер, отмена и повтор. Скачанные архивы проверены по всем файлам manifest и внутренним ссылкам HTML.

Резервная копия создана до изменений. Старые отчёты, данные и выпуск v3 сохраняются отдельно. Копия пользовательской базы восстановлена для испытаний; исходная база не заменяется тестовыми случаями. Итоговая матрица проверки запуска, восстановления и передачи находится в HANDOFF_V4 и ACCEPTANCE_V4.

8. Сопоставление с исходным заданием

Исходный PDF разрешает выбрать один трек, допускает синтетические данные и требует MVP с пятиминутным выступлением. Русский и казахский обязательны; мультимодальность даёт преимущество. Веса критериев: качество 30%, объяснимость 20%, инновационность 20%, практическая применимость 15%, масштабируемость и реализация 10%, презентация 5%.

Основной сценарий трека 2 реализован: скрытое приглашение, OCR/QR, переходы через посредника, связь материалов, ручное решение и объяснимое досье. Механизм работает с новым вводом и сохраняет версии. Для демонстрации подготовлены локальные материалы и резервный сохранённый результат.

Более широкая тема блогеров, стримеров и социальных сетей покрыта лишь через разрешённый импорт материалов. Прямые эфиры, автоматический массовый сбор и короткое видео пока не реализованы. Независимая проверка качества и полезности для аналитика остаётся следующим обязательным шагом перед реальным пилотом. Нельзя обещать победу или превосходство над неизвестными проектами участников; можно показать конкретный работающий процесс и воспроизводимые результаты.

Сильная сторона защиты - возможность пройти от каждого вывода к источнику, объяснить сомнение в OCR и показать честное сравнение двух версий. Граф сам по себе не является доказательством инновационности, а отдельный его вклад в метрики пока не измерен.

9. Что делать дальше

Первый шаг - разрешённые примеры от независимых людей, два разметчика и процедура разбора разногласий. Нужны отдельные домены, кампании и периоды, чтобы проверять перенос качества. Измерять общий recall с отказами, ложные тревоги, достаточность, ошибки URL и время аналитика.

По результатам нового теста улучшать конкретные причины: пропуски символов URL, сложные конструкции призыва, несколько равноправных назначений. Настраивать на новом dev; известный synthetic-v4 больше не использовать как скрытый финальный тест.

Для пилота потребуются права доступа, журнал операций, сроки хранения, согласованные источники и отдельный сетевой исполнитель. PostgreSQL, несколько OCR-исполнителей и централизованная очередь оправданы только измеренной нагрузкой. Текущий localhost MVP не следует публиковать как многопользовательскую систему.

Предпочтительное функциональное расширение - короткое заранее загруженное видео с кадрами, речью и временными метками. Конкретные лимиты и критерии готовности записаны в VIDEO_NEXT.md. Оно отложено до собственной проверки декодирования, языков речи, привязки адресов и стоимости CPU.

10. Где смотреть подробности

Порядок запуска и комплект передачи: docs/HANDOFF_V4.md. Пятиминутный показ: docs/DEMO_V4.md. Полные метрики: reports/EVALUATION_V4.md. Ошибки: reports/ERROR_ANALYSIS_V4.md. Методика: docs/METHODOLOGY.md. Ограничения: docs/LIMITATIONS.md. Исходные предсказания, хеши и сравнение: reports/versions/synthetic-v4. Все материалы локальные; проект не опубликован и не отправлен организаторам.